

钱恒

信息安全专业本科生

信息安全专业本科生，专注于大模型应用开发与LLM 推理系统优化。

具备完整的RAG 系统开发经验，从文档解析、向量检索到 rerank 优化全流程落地；掌握Agent 系统架构设计，实现 tool calling、planning-execution loop 和 memory 管理；深入理解LLM 推理机制，熟悉 vLLM/SGLang 框架及 KV cache、PagedAttention 等核心优化技术。

工程能力扎实，熟练使用 FastAPI 构建后端服务，掌握 Redis/Postgres/Docker 等系统工程工具，具备将 AI 能力产品化的全栈开发能力。

📍 上海

📞 17384339021

@ 20061025@sjtu.edu.cn

— 教育经历

上海交通大学
信息安全专业

2023.09 - 至今
本科

主修课程：网络安全基础、密码学原理、数据结构与算法

— 项目经历

Industrial RAG System for Knowledge QA
工业级 RAG 系统开发

2026.02 - 2026.03

项目描述：构建一个工业级 Retrieval-Augmented Generation (RAG) 系统，用于企业知识库问答，支持文档解析、向量检索、rerank、流式生成等功能。

主要工作：

- 设计并实现完整 RAG pipeline：Document parsing、Chunking、Embedding、Vector retrieval、Rerank、Prompt construction、LLM generation
- 实现文档 ingestion pipeline：支持 PDF/Markdown/HTML 解析，自动 chunk 切分与 embedding，向量数据存储至 Qdrant
- 构建检索优化机制：Hybrid retrieval (BM25 + Vector search)、Cross-encoder rerank、Query rewrite
- 设计低延迟推理服务：vLLM 本地部署、Streaming generation
- 实现系统工程模块：Redis caching、异步任务队列、FastAPI API 服务

项目亮点：支持企业知识库规模文档检索，实现完整 RAG 系统架构，优化 retrieval 质量与推理 latency

Python, FastAPI, LlamaIndex, Qdrant, Redis, vLLM, Docker, RAG, 向量检索

LLM Agent with Tool Use

2026.02 - 2026.03

LLM Agent 系统开发

项目描述：构建一个具备工具调用能力的 LLM Agent，支持多步骤任务执行，如 Web 搜索、代码执行和数据查询等。

主要工作：

- 设计 Agent 架构：planner、executor、tool registry、memory

— 技能

编程语言

Python (熟练), C++ (基础)

Python, C++

算法与数据结构

熟悉 Linux 开发环境，掌握基础算法与数据结构

Linux, 数组, 链表, 栈, 队列, 哈希表, 树, 图, DFS, BFS, 动态规划, 贪心, LeetCode

AI/LLM 技术栈 - RAG

RAG 系统开发全流程：

Document ingestion/chunking/embedding, Vector retrieval/rerank, Prompt engineering

RAG, LlamaIndex, LangChain, Qdrant, Milvus, 向量数据库

AI/LLM 技术栈 - Agent

Agent 系统开发：Tool calling/function calling, Agent planning/execution loop, Memory 管理, multi-step reasoning

Agent, LangGraph, CrewAI, Tool calling

LLM 推理系统

LLM 推理系统：vLLM/SGLang 推理框架, Transformer 推理机制 (KV cache, Prefill/Decode, Continuous batching, PagedAttention)

vLLM, SGLang, Transformer, KV cache, PagedAttention, 推理优化

cache, PagedAttention, 推理优化

Post-training

了解 Post-training 技术：
Instruction tuning/SFT,
LoRA/QLoRA, RLHF/DPO 基本原理



SFT, LoRA, QLoRA, RLHF, DPO

系统工程

FastAPI Python 后端开发，
Redis, Postgres, Docker；理解缓存系统、异步任务队列、基础分布式系统架构



FastAPI, Redis, Postgres, Docker, 缓存系统, 异步任务队列, 分布式系统

- 实现 tool calling system: Web search、Python execution、API tools
- 构建 Agent reasoning loop: thought → tool call → observation → next step
- 实现 Agent memory: short-term memory、conversation state
- 搭建 Agent API 服务: FastAPI、streaming response

项目亮点: 支持复杂任务多步骤执行, 实现完整 agent reasoning loop, 模拟真实 LLM agent system

Python, LangGraph, FastAPI, OpenAI API, Agent, Tool calling

LLM Inference Optimization Study (vLLM) 2026.02 - 2026.03

LLM 推理系统研究

项目描述: 研究大模型推理系统架构, 分析 vLLM 的核心优化技术, 包括 continuous batching、paged attention 和 KV cache 管理。

主要工作:

- 分析 LLM 推理流程: Prefill、Decode、Token generation
- 研究 KV cache 机制: cache allocation、cache reuse、memory bottleneck
- 复现并分析 vLLM 优化技术: continuous batching、paged attention、prefix caching
- 对比不同推理框架: vLLM、SGLang、HuggingFace TGI

项目亮点: 深入理解 LLM 推理系统架构, 分析 GPU 推理性能瓶颈, 掌握推理系统核心优化技术

vLLM, PyTorch, CUDA, 推理优化, KV cache, PagedAttention